Visión por Computadora I

Ing. Maxim Dorogov
(mdorogov@fi.uba.ar)

Laboratorio de Sistemas Embebidos -FIUBA

FACULTAD
DE INGENIERIA
Universidad de Buenos Aires

PROGRAMA SUGERIDO

- **Clase 1:** Introducción a imágenes, sistemas de visión y OpenCV
- **Clase 2:** Op. de píxel, histogramas, binarización, coord. cromáticas
- **Clase 3:** Filtros: Lineales, separables, padding, DoG, Fourier, Bordes (Canny)
- **Clase 4:** Detección de objetos. Algoritmo de Harris. Shi-Tomasi. Hough. Pirámides.
- **Clase 5:** Extracción de características. SIFT, SURF, ORB, FAST, HoG, LBP
- **Clase 6:** Segmentación: k-means, watersheed, mean-shift. Procesamiento morfológico.
- **Clase 7:** Procesamiento de video, gstreamer, ffmpeg, optical flow, sustracción de fondo tracking.
- **Clase 8:** Examen + Teórica opcional.

RÉGIMEN DE APROBACIÓN

- Trabajos prácticos correspondientes a cada unidad temática.
- Examen teórico.

Dinámica esperada para las clases:

- Aprox. 1.5h de teoría
- 15 - 10 minutos de descanso entre cada unidad tematica
- 45 minutos de práctica alternados entre bloques de teoría
- Espacio de consultas

HERRAMIENTAS PARA LA CURSADA

- Lenguaje de programación
  - Python >= 3.8
- Bibliotecas de código
  - Numpy
  - OpenCV/OpenCV-contrib > 3.4
  - Matplotlib
  - Entorno de programación:
    - Jupyter notebook/Google Colab
  - Gestión de entornos: Conda/Miniconda

https://www.anaconda.com/distribution/

BIBLIOGRAFÍA SUGERIDA

- La bibliografía es de referencia y no será obligatorio el uso de la misma.
  - Computer Vision: Algorithms and Applications | Szeliski | Springer
    - http://szeliski.org/Book
  - Computer Vision: A Modern Approach | Forsyth, Ponce | Pearson
  - Computer Vision | Shapiro | Pearson
  - Learning OpenCV | Bradski, Kaehler | O'Reilly

DESAFÍOS

- ¿Por qué puede la visión por computadora resultar compleja?
- Hay tareas complejas que nuestros ojos y cerebro realizan con facilidad pero **no son triviales** para sistemas de visión artificial.

Podemos percibir y entender estas dos imágenes sin mayores inconvenientes…

DESAFÍOS

- ¿Qué podemos resolver con visión por computadora?
- Ejemplos:

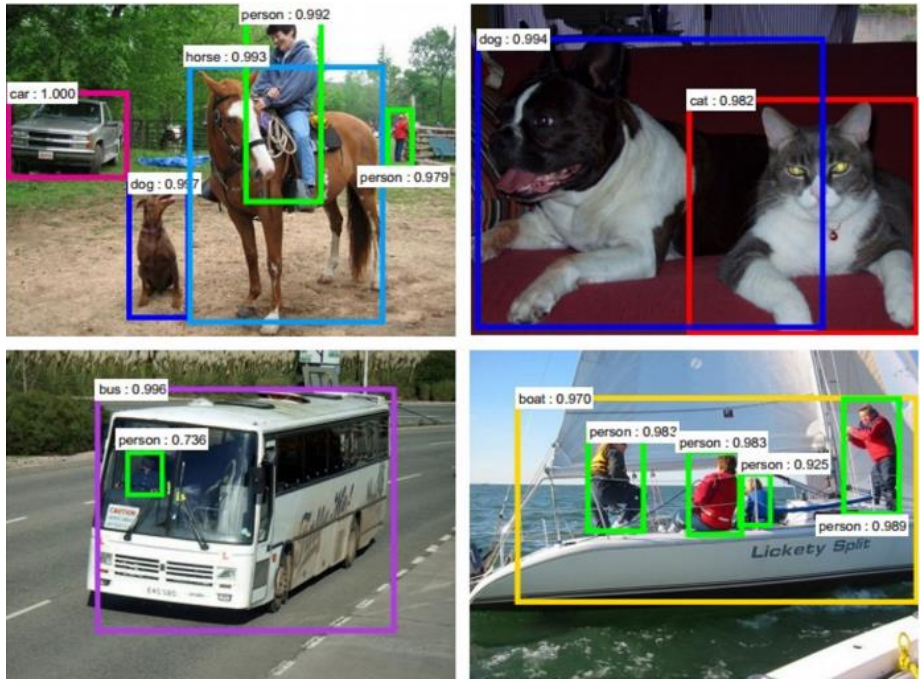

Reconocimiento y detección

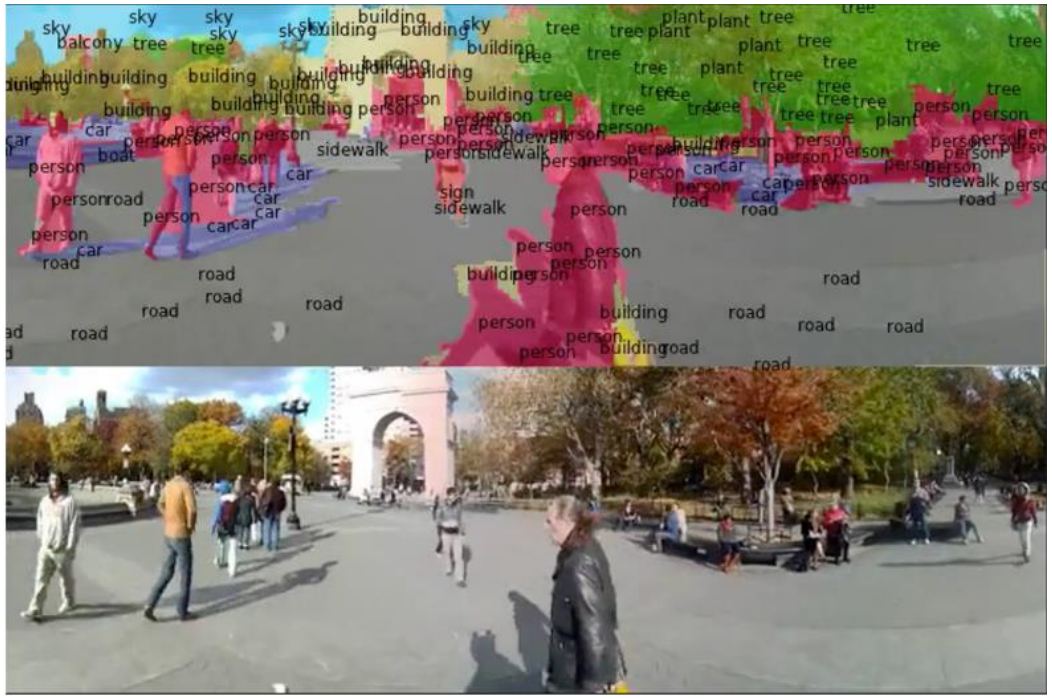

Segmentación de objetos

DESAFÍOS

- Mas ejemplos:

Extracción y detección de características o keypoints. (SIFT, David Lowe, 1999)

DESAFÍOS

- Mas ejemplos:

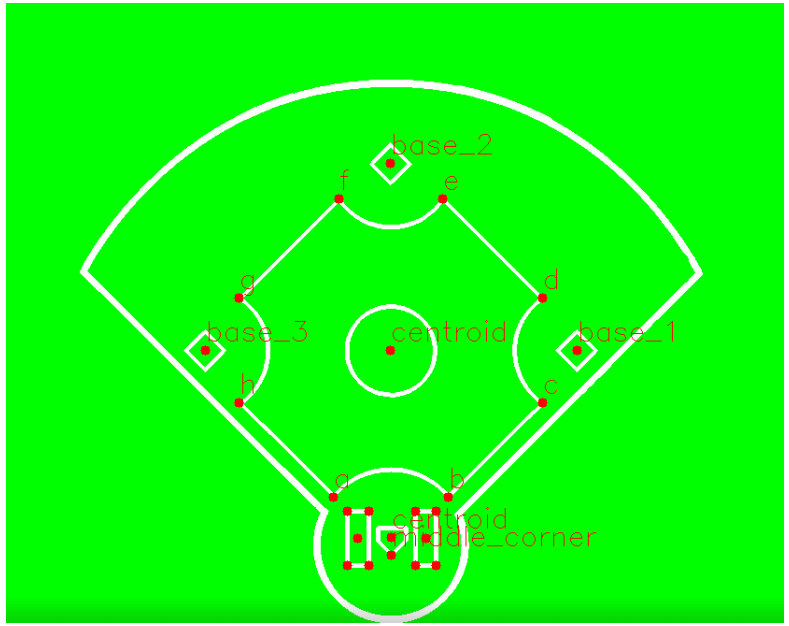

Detección y mapeo de keypoints y puntos de control en un campo de baseball.

DESAFÍOS

- Mas ejemplos:

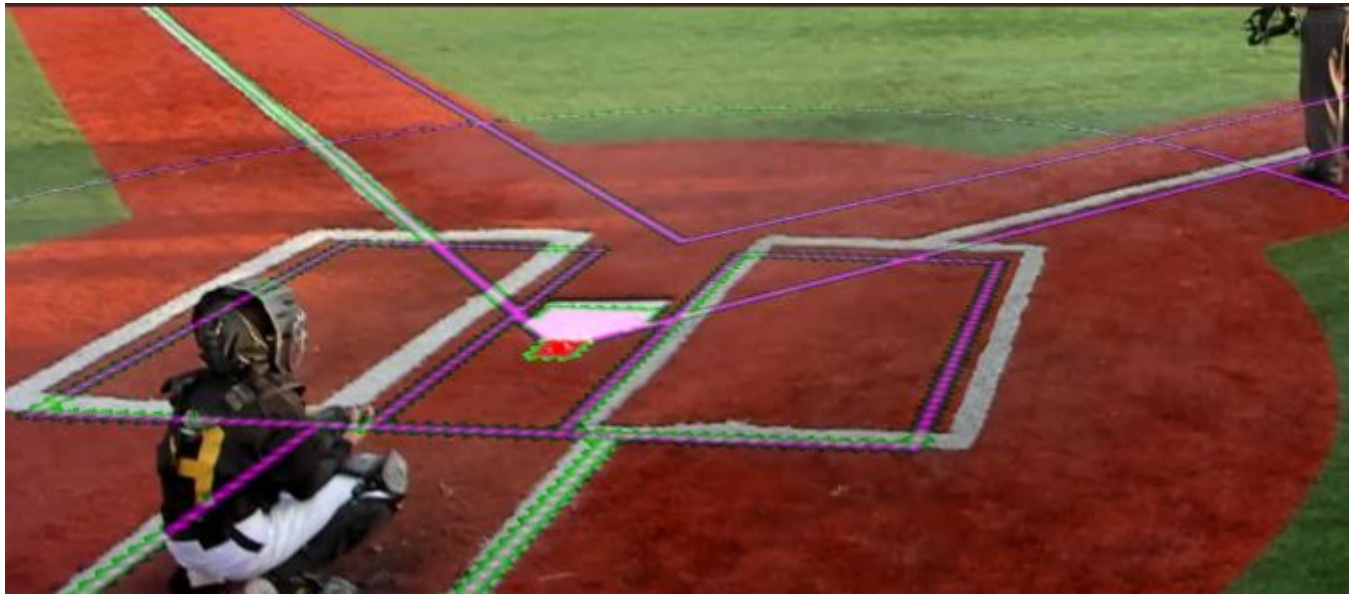

Mapeo y proyección entre el plano de la imagen y el plano de control.

DESAFÍOS

- Mas ejemplos: Modelos generativos

Inpainting mediante stable diffusion 2

Se cambia el fondo, se puede usar para poner publicidad

DESAFÍOS

- Mas ejemplos: Tratar señales 1D como imágenes mediante espectrogramas.

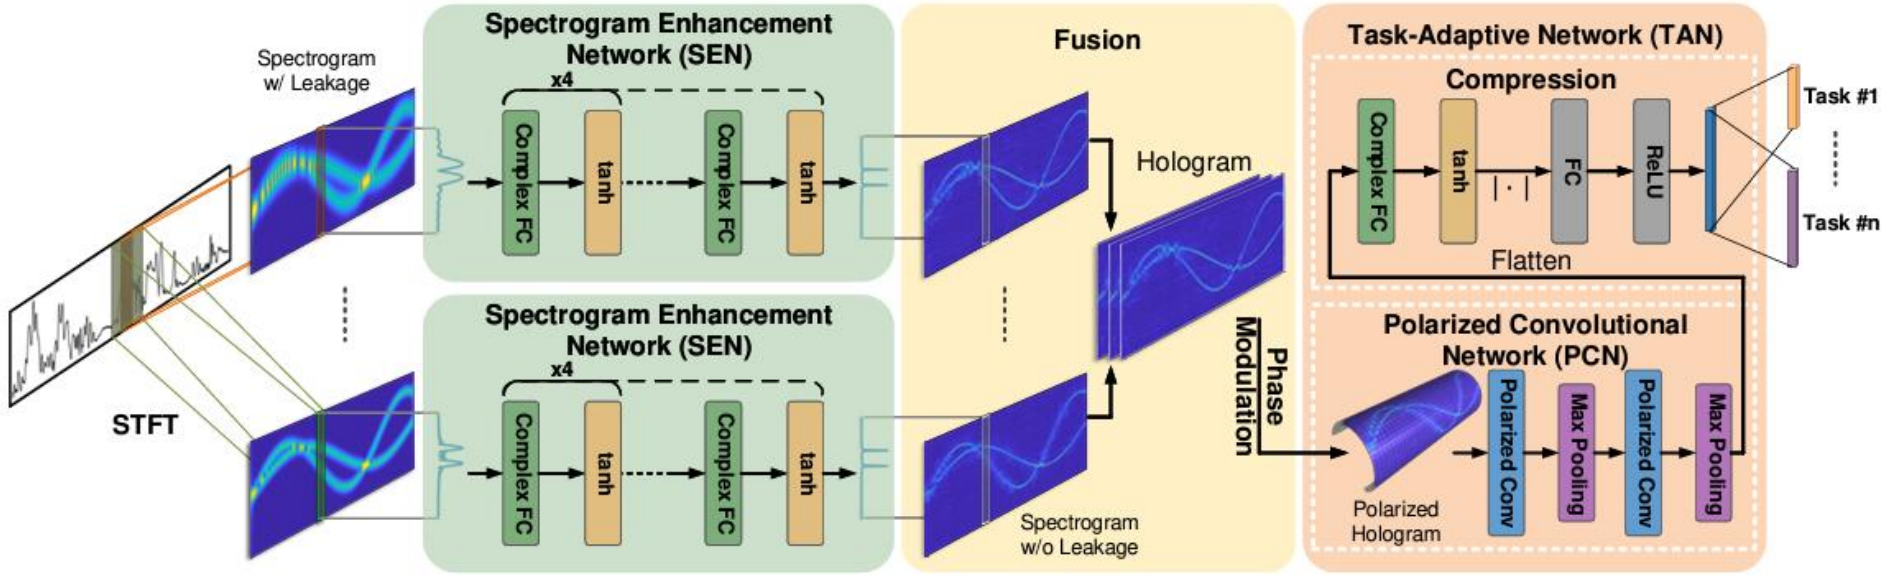

SLNet (2023): Procesa espectrogramas para extraer características de series temporales

DESAFÍOS

- Mas ejemplos: Modelos generativos V-LLM

Generación de fotogramas con Veo2 y Google AI Studio

DESAFÍOS

- Mas ejemplos: Modelos multi modales

```
Processing video: ./ai_shop.mp4
video input: torch.Size([16, 3, 364, 644])
num of used video tokens: 2392
{
  'suspicious_behavior': False,
  'description’:
        'The video shows a man walking through a grocery store aisle,
        picking up a snack from the shelf, and putting it into his jacket pocket.
        There is no indication of any suspicious activity.’
}
```

Es bueno para predecir pero no para inferir

Descripción provista por Qwen2.5-7B-AWQ para el video anterior.

DESAFÍOS

- Mas ejemplos:

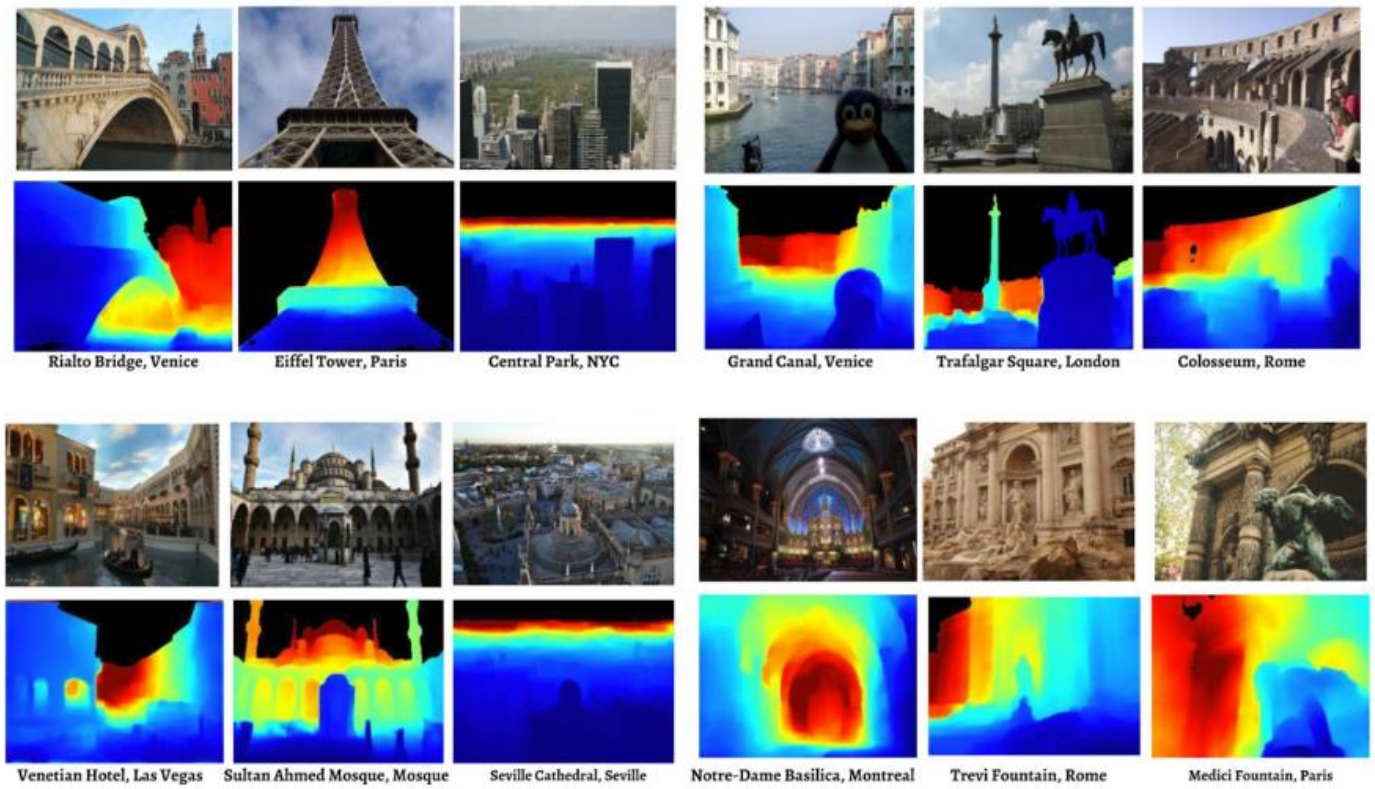

Estimación de profundidad

Para estimar la profundidad se necesita dos camaras con las mismas caracteristicas.

DESAFÍOS

de Computer Vision

- Hoy en día es uno de los campos interdisciplinarios mas estudiados y con mayores aplicaciones en la vida cotidiana.

NASA's Mars Curiosity Rover

Amazon Scout

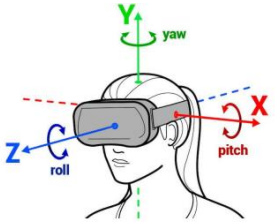

6DoF head tracking

Hand & body tracking

3D scene understanding

3D-360 video capture

Vehículos asistidos

DESAFÍOS

- Desde chicos ya estábamos familiarizados con sistemas de visión artificial:

HISTORIA Y APLICACIONES

1970 1980 1990 2000 2010 2020

Digital image processing
Blocks world, line labeling
Generalized cylinders
Pattern recognition
Stereo correspondence
Intrinsic images
Optical flow
Structure from motion
Image pyramids
Shape from shading, texture, and focus
Physically-based modeling
Regularization
Markov random fields
Kalman filters
3D range data processing
Projective invariants
Factorization
Physics-based vision
Graph cuts
Particle filtering
Energy-based segmentation
Face recognition and detection
Image-based modeling and rendering
Texture synthesis and inpainting
Computational photography
Feature-based recognition
Category recognition
Machine learning
Modeling and tracking humans
Semantic segmentation
SLAM and VIO
Deep learning
Vision and language

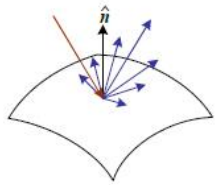

2. Image formation


3. Image processing


4. Optimization

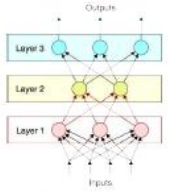

5. Deep learning


6. Recognition


7–8. Features & alignment


9. Motion estimation

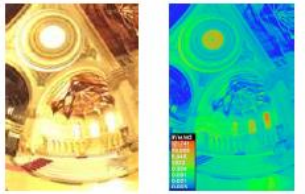
10. Computational Photography


11. Structure from motion


12. Depth estimation


13. 3D reconstruction

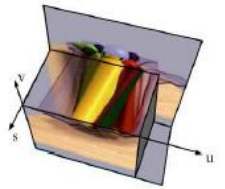

14. Image-based Rendering

Visión por computadora: Historia y campos de aplicación

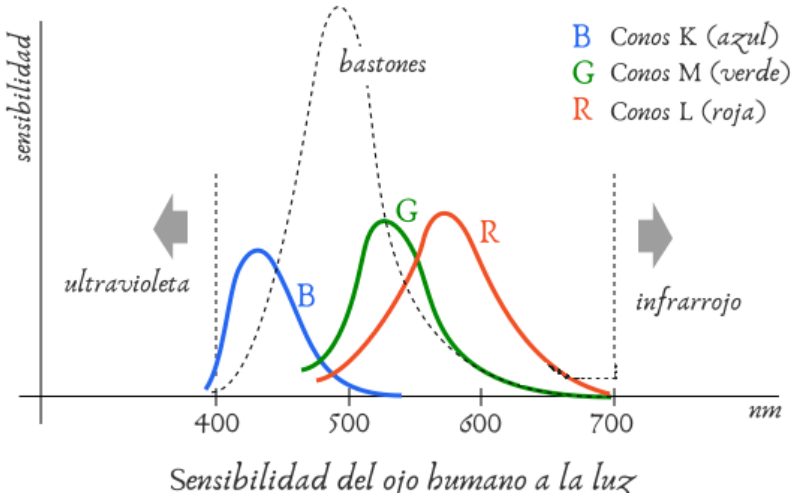

Sensibilidad del ojo humano a la luz

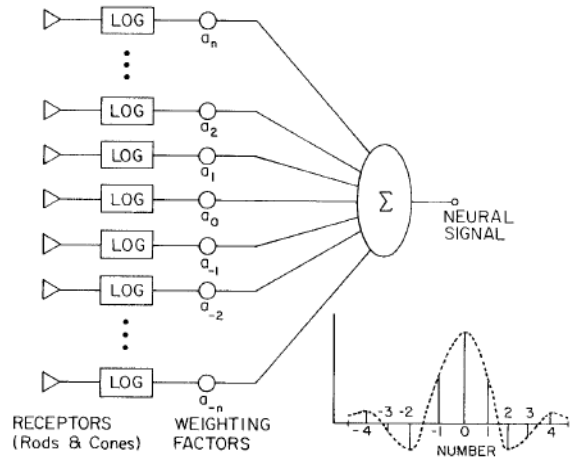

FIGURE 2.4-6. Lateral inhibition effect.

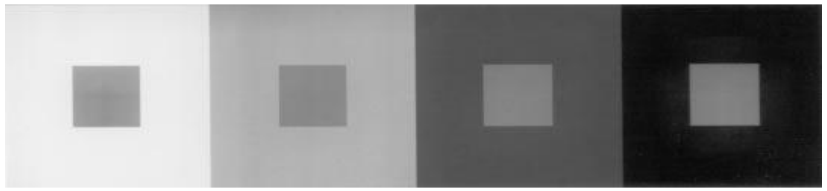

PERCEPCIÓN DE LA LUZ POR EL OJO

- Bastones: Intensidad (responden poco al rojo). 120 millones
- Conos: Color (concentrados en la mácula). 6~7 millones
  - Rojos – 64%
  - Verdes – 32 %
  - Azules – 2 %
- Respuesta logarítmica. Fracción de Weber (0.02)
- Daltonismo (8% hombres / 1% mujeres)

MODELOS DE COLOR

- RGB: Commission Internationale d'Eclairage (CIE) en 1930
  - Rojo: 700 nm
  - Verde: 546,1 nm
  - Azul: 435,8nm
- XYZ: Resuelve el color negativo

$$\begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = \frac{1}{0{,}17697} \begin{bmatrix} 0{,}49 & 0{,}31 & 0{,}20 \\ 0{,}17697 & 0{,}81240 & 0{,}01063 \\ 0{,}00 & 0{,}01 & 0{,}99 \end{bmatrix} \begin{bmatrix} R \\ G \\ B \end{bmatrix}$$

Además, permite separar crominancia de luminancia

$$x = \frac{X}{X+Y+Z} \qquad y = \frac{Y}{X+Y+Z} \qquad z = \frac{Z}{X+Y+Z}$$

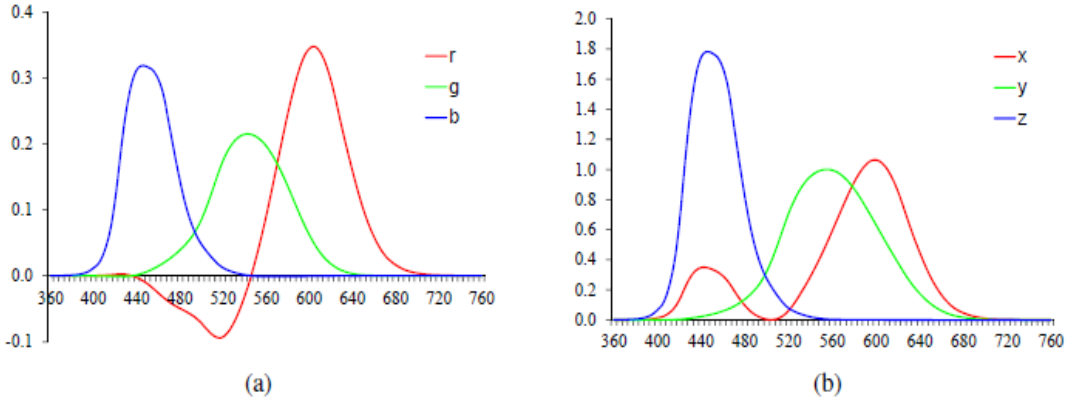

Figure 2.28 Standard CIE color matching functions: (a) $\bar{r}(\lambda)$, $\bar{g}(\lambda)$, $\bar{b}(\lambda)$ color spectra obtained from matching pure colors to the R=700.0nm, G=546.1nm, and B=435.8nm primaries; (b) $\bar{x}(\lambda)$, $\bar{y}(\lambda)$, $\bar{z}(\lambda)$ color matching functions, which are linear combinations of the $(\bar{r}(\lambda), \bar{g}(\lambda), \bar{b}(\lambda))$ spectra.

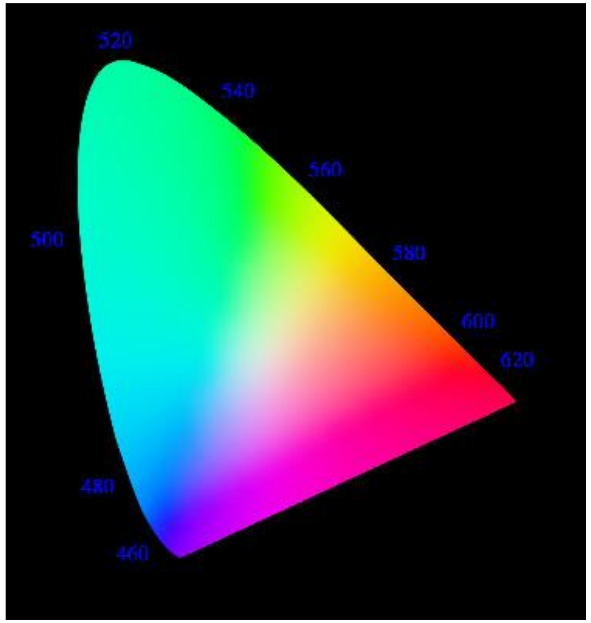

OTROS ESPACIOS DE COLOR

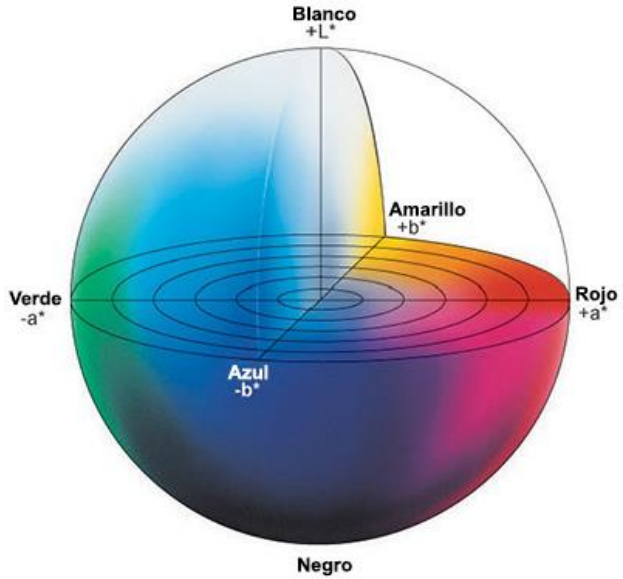

- **CIELAB** (L*a*b)

$$L^* = 116\, f\left(\frac{Y}{Yn}\right); \quad a^* = 500\left[f\left(\frac{X}{Xn}\right) - f\left(\frac{Y}{Yn}\right)\right]; \quad b^* = 200\left[f\left(\frac{Y}{Yn}\right) - f\left(\frac{Z}{Zn}\right)\right]$$

$$f(t) = \begin{cases} t^{1/3} & si\ t > \delta^3 \\ \frac{t}{3\delta^2} + \frac{2\delta}{3} & otro\ caso \end{cases}$$

- **HSV**
  - **Hue:** Dirección alrededor de la rueda de color, en grados $\in [0, 360]$ [0, 180]
  - **Saturation:** Distancia escalada desde la diagonal $\in [0, 1]$
  - **Value:** Promedio o máximo valor de color $\in [0, 1]$ 0, 255

En OpenCV

Conversión RGB → HSV

- $V = M = \max(R, G, B)\,;\ m = \min(R, G, B)$
- $S = (M - m)/M \quad (S = 0, si\ V = 0)$
- $$H = 60 \times \begin{cases} 0 & ,si\ (M - m) = 0 \\ 0 + (G - B)/(M - m), & si\ max = R \\ 2 + (B - R)/(M - m), & si\ max = G \\ 4 + (R - G)/(M - m), & si\ max = B \end{cases}$$

$$H = H + 360, si\ H < 0$$

SISTEMAS DE VISIÓN

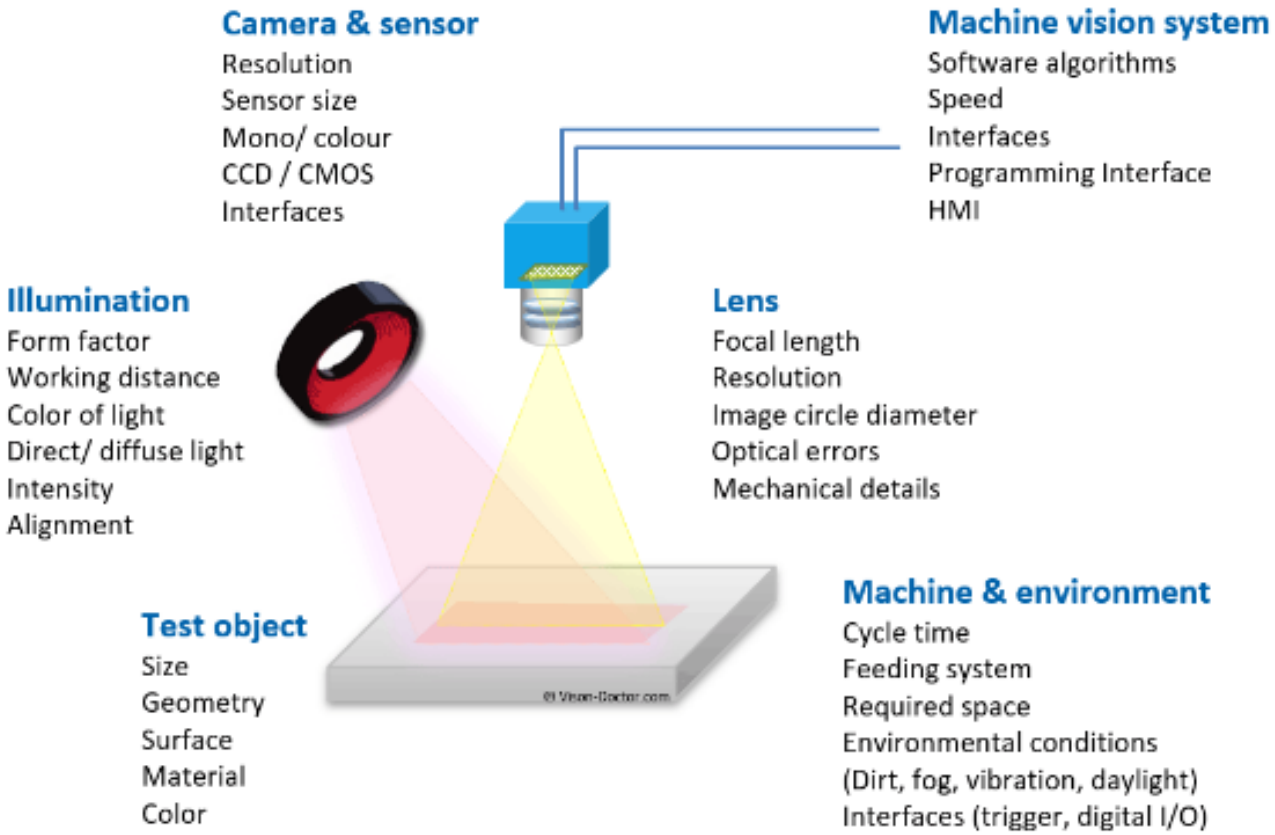

- Cámara:
  - Sensores CMOS o CCD.
  - Tipo de shutter
  - Tipo de interfaz (USB, Ethernet, etc…)
  - LUTs
  - Depth Camera
  - Smart
  - Etc…
- Lente:
  - Telecéntrica : solo se usa metrologia
  - Entocéntrica
- Iluminación:
  - Campo oscuro (Dark field)
  - Luz directa
  - Luz difusa (Domo)
  - Backlight
  - Color
- Procesamiento
  - Cloud
  - Edge

ILUMINACIÓN

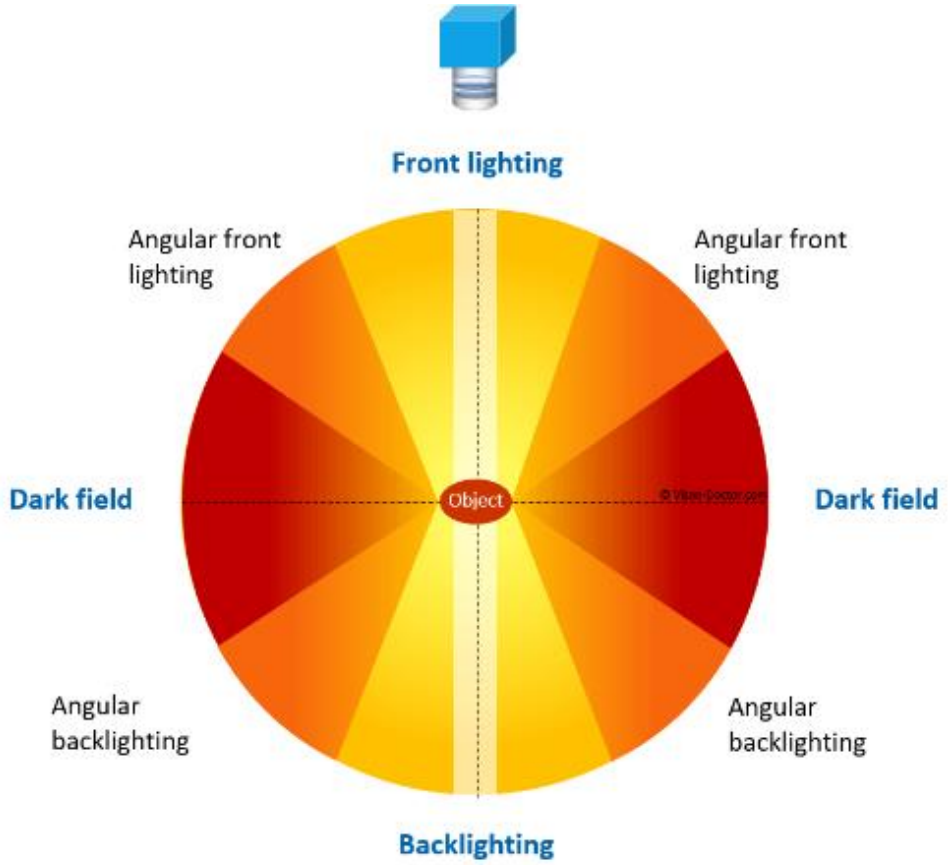

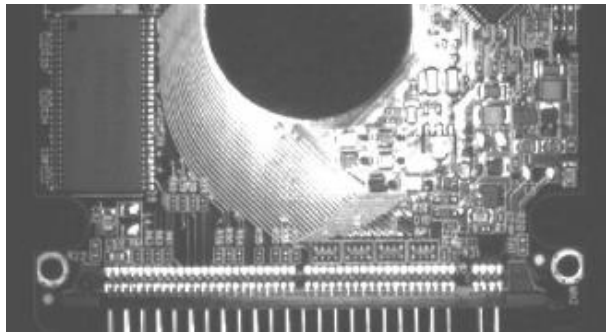

Luz directa

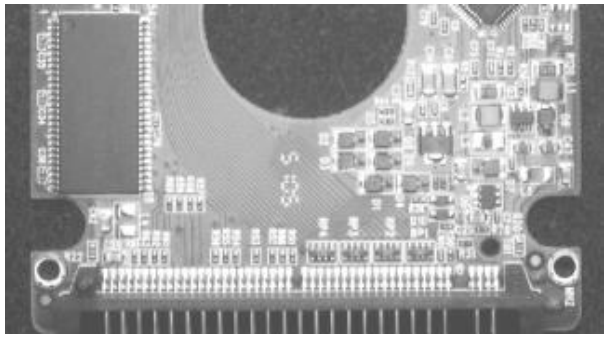

Luz con difusor

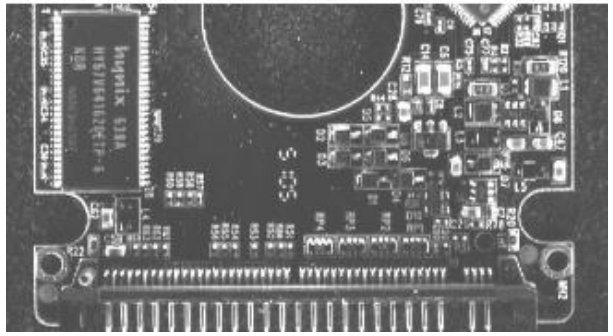

Dark Field

Backlight

ILUMINACIÓN

Iluminación por encima (y debajo) del espectro visible:

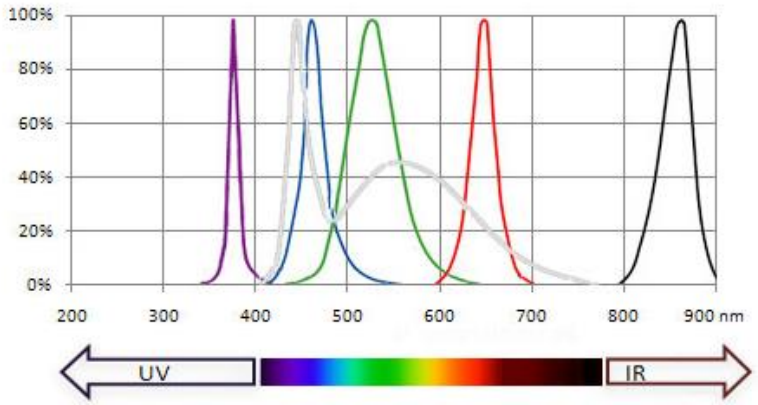

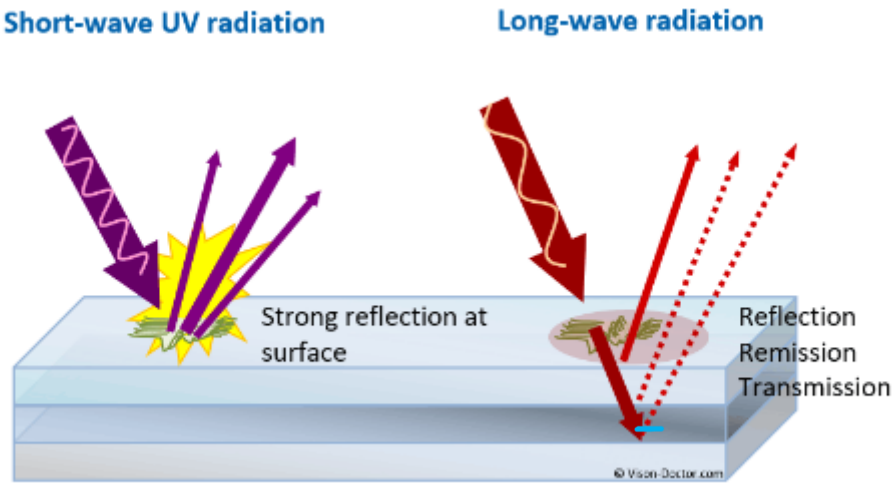

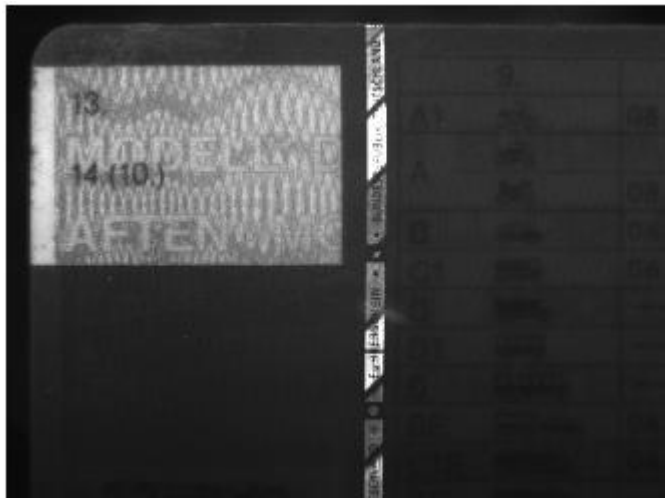

Luz ultravioleta: Permite ver capas internas del material a analizar

Algo similar sucede cuando se utiliza luz infrarroja

LENTE

Principalmente se dividen en etnocéntrica y telecéntrica, las primeras producen un error de perspectiva y son las lentes mas comunes usadas en fotografía, cine, y aplicaciones de consumo masivo.

Lens class	Aperture angle
Tele lens	< 20 °
Long focal length lens	20-40 °
Normal lens	40-55 °
Wide angle lens	> 55 °
Super wide angle lens	~ 110°
Fisheye lens	~ 180°

Tipos de lente etnocéntrica

La lente telecéntrica corrige los errores de perspectiva ya que los rayos de luz inciden paralelos al eje óptico de la cámara. Son usadas principalmente en metrología y no tienen aplicaciones por fuera del ambiente industrial.

Lente etnocentrica, (izquierda) y telecéntrica (derecha)

TIPOS DE SENSORES

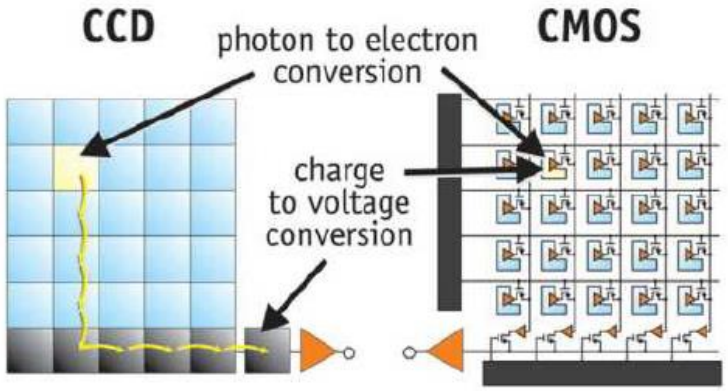

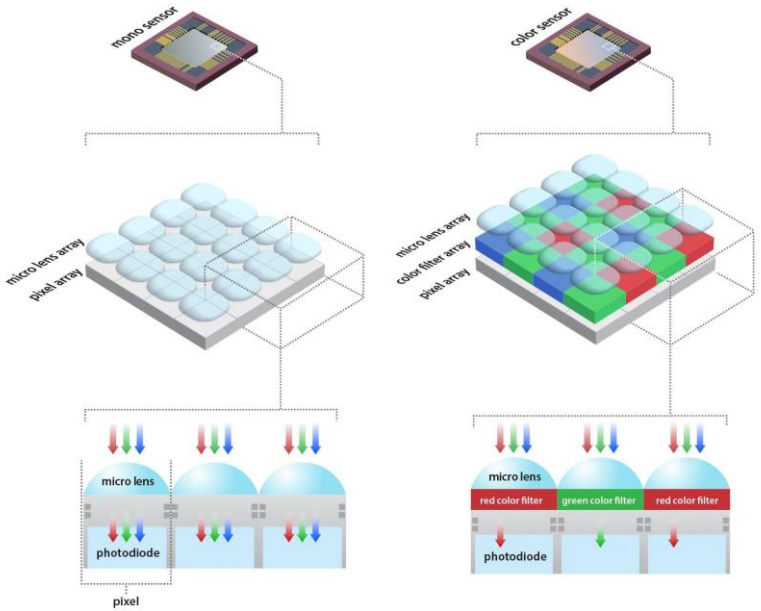

- **CCD** (charge-couple device): Willard Boyle y George E. Smith – Laboratorios Bell – 1969
  - A/D central 20 a 75MHz
  - Blooming/ Smearing
  - Mayor sensibilidad
- **CMOS** (complementary metal oxide semiconductor)
  - Conversión en el fotositio
  - Rolling shutter
  - Microlentes que procesan el haz de luz

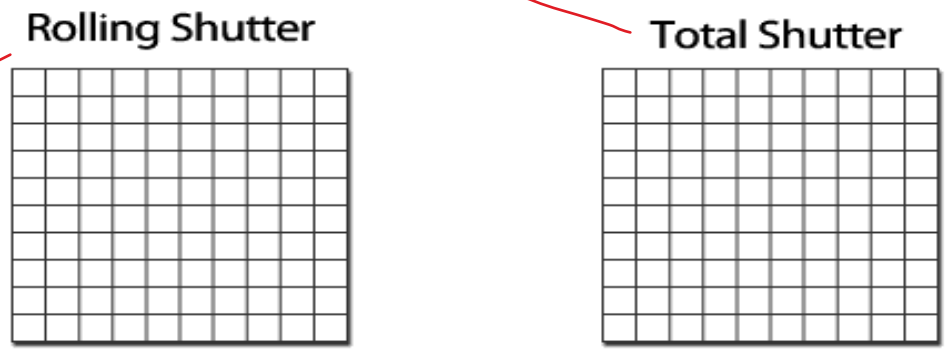

CÁMARA DIGITAL

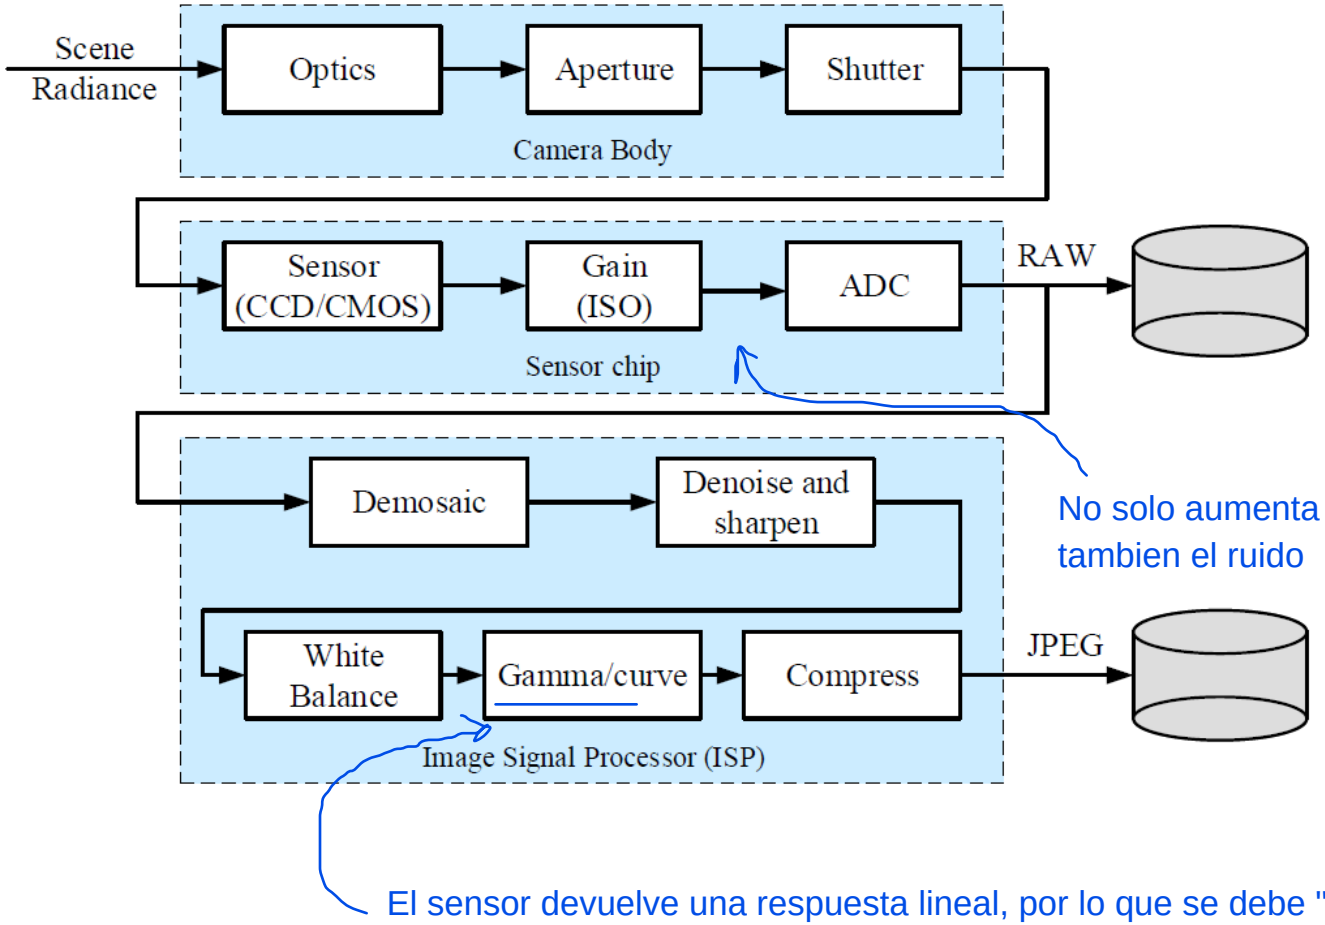

Las cámaras profesionales y de aplicaciones especificas permiten, además de una imagen, obtener los datos en formato RAW. (Raster en aplicaciones espaciales)

- No es un "formato" estandarizado
- Algunos formatos de datos RAW: TIFF, CR2, 3FR, NRW.
- Ocupan 3 veces (o mas!) de espacio que un archivo de imagen.

No solo aumenta la intensidad de la imagen, tambien el ruido

Muchas veces en la cámara se efectúa un post procesamiento digital para compensar las falencias del sistema óptico (lente-sensor), algo típico en teléfonos celulares o cámaras hogareñas.

El sensor devuelve una respuesta lineal, por lo que se debe "deslinealizar". Esta corrección ajusta la intensidad a valores como lo veriamos nosotros.

REPRESENTACIÓN DE IMÁGENES

- NxMx1 si la imagen esta en escala de grises
- NxMx3 para imágenes a color
- Rango: 0 (pixel apagado) – 255 (max. Intensidad) con uint8 para indicar la intensidad de cada pixel
- También existen imágenes binarias, se utilizan como mascaras
- En OpenCV y Numpy se indexa por [N-fil, N-col, N-canal]

Eje X (columnas)

Eje Y (filas)

Ejemplo: una imagen con resolución 1920x1080 px, si se hace img.shape devuelve (1080, 1920)

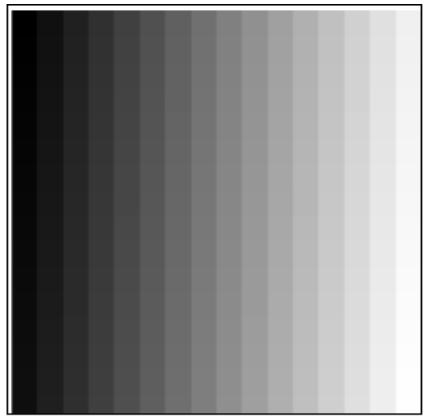

0	16	32	48	64	80	96	112	128	144	160	176	192	208	224	240
1	17	33	49	65	81	97	113	129	145	161	177	193	209	225	241
2	18	34	50	66	82	98	114	130	146	162	178	194	210	226	242
3	19	35	51	67	83	99	115	131	147	163	179	195	211	227	243
4	20	36	52	68	84	100	116	132	148	164	180	196	212	228	244
5	21	37	53	69	85	101	117	133	149	165	181	197	213	229	245
6	22	38	54	70	86	102	118	134	150	166	182	198	214	230	246
7	23	39	55	71	87	103	119	135	151	167	183	199	215	231	247
8	24	40	56	72	88	104	120	136	152	168	184	200	216	232	248
9	25	41	57	73	89	105	121	137	153	169	185	201	217	233	249
10	26	42	58	74	90	106	122	138	154	170	186	202	218	234	250
11	27	43	59	75	91	107	123	139	155	171	187	203	219	235	251
12	28	44	60	76	92	108	124	140	156	172	188	204	220	236	252
13	29	45	61	77	93	109	125	141	157	173	189	205	221	237	253
14	30	46	62	78	94	110	126	142	158	174	190	206	222	238	254
15	31	47	63	79	95	111	127	143	159	175	191	207	223	239	255

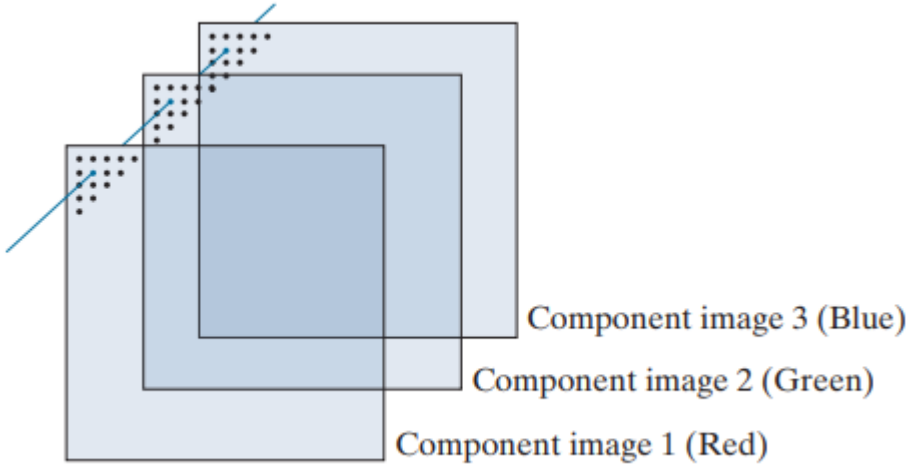

Se toma la esquina superior izquierda como origen (y=0, x=0) de coordenadas